

— پروژه اول —

چرا امروز می‌توانیم با ماشین گفت‌وگو کنیم؟

توضیحی کوتاه و غیرتخصصی از این‌که چرا ایده هوش مصنوعی قدیمی است، اما دستیارهای زبانی امروزی تازه در سال‌های اخیر عملی و فراگیر شده‌اند.

Mehdi Ghorbani

مهدی قربانی

هدف این نوشته، پاسخی کوتاه و غیرتخصصی به این پرسش است: چرا ایده هوش مصنوعی قدیمی است، اما دستیارهای زبانی امروزی تازه در سال‌های اخیر عملی و فراگیر شده‌اند؟

روش تحقیق

این متن با کمک یک چت‌بات برای یافتن منابع اولیه تهیه شد، سپس ادعاها با مقاله‌های علمی و گزارش‌های پژوهشی بازبینی و ساده‌سازی شدند. بنابراین نباید آن را فهرستی از نام مدل‌ها دانست؛ پرسش اصلی آن این است: چه چیزهایی باید هم‌زمان فراهم می‌شد تا گفت‌وگو با ماشین ممکن شود؟

۱ از «قانون» تا «یادگیری»

در برنامه‌نویسی مبتنی بر قواعد، انسان از قبل تصمیم می‌گیرد ماشین در هر وضعیت چه کند: «اگر کاربر این واژه را نوشت، آن پاسخ را بده». این روش برای مسئله‌های کوچک و روشن خوب است، اما زبان طبیعی بی‌نهایت است: جمله‌ها، منظورها، استثنائات و لحن‌ها را نمی‌توان به‌طور کامل به هزاران قانون تبدیل کرد.

یادگیری ماشین مسیر را عوض کرد. به جای نوشتن همه قواعد، برنامه نمونه‌های فراوان می‌بیند و پارامترهای درونی خود را طوری تغییر می‌دهد که الگوها را بهتر پیش‌بینی کند. در یک مدل زبانی، تمرین پایه معمولاً ساده است: با دیدن متن پیشین، «توکن» یا قطعه بعدی متن را حدس بزن. با تکرار این کار روی حجم بسیار بزرگی از متن، مدل الگوهای دستور زبان، ارتباط واژه‌ها، سبک‌ها و بخشی از دانش بازتاب‌یافته در متن را در پارامترهایش فشرده می‌کند. این به معنی فهم انسانی یا تضمین درستی نیست؛ مدل همچنان می‌تواند پاسخ ساختگی و قانع‌کننده تولید کند.

یادگیری عمیق، یعنی شبکه‌هایی با لایه‌های زیاد، این فرایند را نیرومندتر کرد: به جای آن‌که مهندس ویژگی‌های زبانی را دستی طراحی کند، لایه‌ها بازنمایی‌های چندسطحی را از داده می‌آموزند و با «پس‌انتشار خطا» پارامترها را اصلاح می‌کنند.

منبع کلیدی: LeCun, Bengio & Hinton, «Deep learning», Nature, 27 مه 2015. این مرور توضیح می‌دهد که شبکه‌های چندلایه با پس‌انتشار، بازنمایی‌های پیچیده را مستقیماً از داده می‌آموزند.

۲ چرا ترنسفورمر نقطه عطف بود؟

متن فقط زنجیره‌ای از واژه‌های کنار هم نیست؛ واژه‌ای در ابتدای جمله ممکن است به واژه‌ای بسیار دور وابسته باشد. مدل‌های قدیمی‌تر دنباله‌ای اغلب متن را گام‌به‌گام می‌خواندند؛ بنابراین آموزش آن‌ها روی متن بلند و حجم عظیم دشوارتر بود.

معماری ترنسفورمر (2017) از سازوکاری به نام «توجه» استفاده می‌کند: هنگام ساخت یا تحلیل هر بخش متن، مدل می‌آموزد به کدام بخش‌های دیگر متن بیشتر نگاه کند. نکته اقتصادی و مهندسی مهم این است که بسیاری از محاسبات آن می‌توانند موازی اجرا شوند؛ در نتیجه با GPUها و خوشه‌های بزرگ سازگاری بیشتری دارد. مقاله اصلی گزارش کرد که ترنسفورمر در ترجمه کیفیت بالاتری از مدل‌های رقیب داشت و آموزش آن موازی‌پذیرتر و کم‌زمان‌تر بود.

ترنسفورمر به‌تنهایی یک دستیار گفت‌وگویی نمی‌سازد، اما راهی عملی برای بزرگ‌کردن هم‌زمان مدل، داده و آموزش فراهم کرد. در کار GPT-3 نیز دیده شد که با بزرگ‌تر شدن مدل، توانایی انجام برخی کارها از روی چند نمونه نوشته‌شده در خود درخواست (few-shot) بهتر شد؛ یعنی کاربر می‌توانست با زبان عادی، تا حدی وظیفه را تعریف کند.

منابع کلیدی: Vaswani و همکاران، «Attention Is All You Need»، NeurIPS, 12، Brown و همکاران، «Language Models are Few-Shot Learners»، NeurIPS, 2020.

۳ داده کافی نبود: چهار شرطی که باید کنار هم می‌آمدند

داده متنی دیجیتال و وب منبع بزرگی از مثال‌ها فراهم کرد، اما داده به‌تنهایی مدل نمی‌سازد. دستیارهای امروز حاصل هم‌زمانی چهار عامل‌اند:

داده زیاد و آماده‌سازی‌شده

متن‌های فراوان باید گردآوری، پاک‌سازی، تکراری‌زدایی، توکن‌بندی و تا حد امکان پالایش شوند. داده بد می‌تواند سوگیری، خطا یا اطلاعات نامناسب را وارد مدل کند.

توان پردازشی

آموزش میلیاردها یا تریلیون‌ها پارامتر، تعداد بسیار زیادی ضرب ماتریسی می‌خواهد. GPU/شتاب‌دهنده‌ها، حافظه، شبکه پرسرعت و نرم‌افزار آموزش توزیع‌شده لازم بود تا این کار در زمان قابل‌قبول ممکن شود.

روش آموزش و مقیاس‌دهی

باید مدل، مقدار داده و محاسبه متناسب انتخاب شوند؛ بزرگ‌کردن فقط یکی از آن‌ها معمولاً اتلاف است. پژوهش‌های مقیاس‌دهی نشان داده‌اند عملکرد مدل زبانی با افزایش این سه عامل، تا وقتی عامل دیگر گلوگاه نشده باشد، بهبود منظم دارد.

سرمایه‌گذاری و زیرساخت

ساخت خوشه‌های محاسباتی، پرداخت هزینه برق و تراشه، جذب پژوهشگر و ارزیابی ایمنی هزینه‌بر است. سرمایه‌گذاری صنعتی، ابررایانش ابری، ابزارهای متن‌باز و رقابت پژوهشی سرعت آزمون و انتشار روش‌ها را بالا برده‌اند.

پس پاسخ کوتاه به «چرا زودتر ساخته نشد؟» این است: ایده شبکه عصبی و پیش‌بینی متن وجود داشت، اما ترکیب داده دیجیتال وسیع، سخت‌افزار مناسب، الگوریتم مقیاس‌پذیر، مهندسی توزیع‌شده و سرمایه لازم هنوز مهیا نبود.

منابع کلیدی: Kaplan و همکاران، «Scaling Laws for Neural Language Models»، 2020؛ «The 2025 AI Index Report»، Stanford HAI، گزارش استنفورد برآورد می‌کند محاسبه آموزشی مدل‌های شاخص تقریباً هر پنج ماه دوبرابر شده است؛ این یک روند مشاهده‌شده است، نه قانون طبیعی همیشگی.

۴ از کامل‌کردن متن تا دستیار گفت‌وگویی

مدل پایه عمدتاً یاد می‌گیرد ادامه محتتمل متن چیست. چنین مدلی ممکن است جواب را کامل کند، اما الزاماً درخواست کاربر را دنبال نمی‌کند، مفید نیست یا از گفتن محتوای زیان‌بار پرهیز نمی‌کند. برای تبدیل آن به دستیار معمولاً این مراحل افزوده می‌شود:

پیش‌آموزش

پیش‌بینی توکن بعدی روی متن‌های بسیار زیاد.

تنظیم با نمونه دستور

انسان‌ها نمونه‌هایی از پرسش و پاسخ مطلوب می‌نویسند تا مدل یاد بگیرد توضیح دهد، قالب را رعایت کند و گفت‌وگویی‌تر پاسخ بدهد.

بازخورد انسانی

ارزیاب‌ها چند پاسخ را مقایسه و رتبه‌بندی می‌کنند. از این ترجیح‌ها برای تنظیم بیشتر مدل استفاده می‌شود (از جمله روش‌هایی مانند RLHF).

ارزیابی و محافظ‌ها

آزمون خطا، سوگیری، امنیت، حفظ حریم خصوصی و مقاومت در برابر درخواست‌های سوءاستفاده؛ سپس اعمال سیاست‌ها، فیلترها و گاهی اتصال محدود به ابزارهای بیرونی.

مقاله InstructGPT نشان داد تنظیم با نمایش‌های انسانی و سپس بازخورد انسانی می‌تواند پاسخ‌های مدل را با نیت کاربر هم‌راست‌تر کند؛ در ارزیابی انسانی همان پژوهش، نسخه ۱/۳ میلیاردپارامتری تنظیم‌شده بر نسخه ۱۷۵ میلیاردپارامتری GPT-3 ترجیح داده شد. این نتیجه به معنی حل‌شدن مسئله «هم‌راستایی» نیست، بلکه نشان می‌دهد کیفیت گفت‌وگو فقط با بزرگ‌کردن مدل تعیین نمی‌شود.

منبع کلیدی: Ouyang و همکاران، «6»، NeurIPS، «Training Language Models to Follow Instructions with Human Feedback» دسامبر 2022.

۵ سرعت، محدودیت‌ها و معنای «نمایی»

پیشرفت را نباید با یک واژه مبهم مانند «نمایی» خلاصه کرد؛ ابتدا باید شاخص را تعیین کنیم:

شاخص	چه چیزی دیده می‌شود؟	آیا حتماً نمایی است؟
توانایی	نمره آزمون‌ها و کیفیت در وظایف مشخص بهتر شده است، اما آزمون‌ها محدودند و با توانایی عمومی یا حقیقت‌گویی یکی نیستند.	نه؛ جهش‌ها و اشباع‌ها بسته به آزمون و روش رخ می‌دهند.
هزینه استفاده	هزینه اجرای مدلی در سطح GPT-3.5، طبق AI Index، از 20 دلار به 0.07 دلار برای یک میلیون توکن بین نوامبر 2022 و اکتبر 2024 رسید.	کاهش بسیار سریع بوده، اما تداوم آن تضمین‌شده نیست.
سرعت پیشرفت پژوهش	اشتراک مقاله، ابزار، داده و رقابت تجاری چرخه آزمون را کوتاه کرده‌اند.	ممکن است دوره‌ای شتاب‌دار باشد، ولی به منابع و بازده پژوهش وابسته است.

عوامل شتاب‌دهنده شامل تراشه‌های بهتر، روش‌های کارآمدتر، مدل‌های کوچک‌تر اما توانمند، داده و بازخورد باکیفیت، دسترسی ابری و سرمایه‌گذاری‌اند. در مقابل، کمبود داده باکیفیت، هزینه و برق آموزش، محدودیت تراشه و زنجیره تأمین، حق نشر و حریم خصوصی، مقررات، دشواری ارزیابی، خطا و جعل واقعیت، و کاهش بازده مقیاس می‌توانند سرعت را کند کنند.

منبع کلیدی: 2025، «The 2025 AI Index Report»، Stanford HAI. این گزارش کاهش بیش از 280 برابری هزینه استنتاج سطح GPT-3.5 را در حدود 18 ماه گزارش می‌کند، اما هم‌زمان رشد نیاز محاسباتی و انرژی مدل‌های شاخص را نیز نشان می‌دهد.

۶ اگر به سال ۲۰۱۰ برگردیم

در 2010 می‌توانستیم یک دستیار محدود بسازیم: موتور جست‌وجو، بازیابی پاسخ از پایگاه دانش، تشخیص گفتار/ترجمه آماری یا ابتدایی، و قواعد دستی برای حوزه‌ای بسته مانند پشتیبانی یک شرکت. داده وب وجود داشت و GPUها رو به رشد بودند، اما ابزارها و اجزای مهم امروز هنوز کم‌رشد یا غایب بودند: ترنسفورمر 2017، چارچوب‌های بالغ برای آموزش توزیع‌شده در مقیاس بسیار بزرگ، خوشه‌های ابری فراوان، داده پالایش‌شده عظیم، دستورالعمل و ترجیح انسانی در حجم بالا، و شواهد روشن درباره چگونگی مقیاس‌دادن مدل‌های زبانی.

بنابراین دستیار 2010 احتمالاً در سناریوهای ازپیش‌تعریف‌شده خوب عمل می‌کرد، ولی گفت‌وگویی باز، انعطاف‌پذیر و چندوظیفه‌ای مانند ابزارهای امروز نبود. تفاوت اصلی «هوشمندشدن ناگهانی ماشین» نیست؛ انباشته‌شدن چند پیش‌شرط فنی، اقتصادی و اجتماعی است که سرانجام یادگیری از داده را در مقیاسی عملی ممکن کرد.

• • •

منابع منتخب

— LeCun, Yann; Bengio, Yoshua; Hinton, Geoffrey. «Deep learning» Nature، جلد 521، صص. 436–444، 27 مه 2015.
<https://doi.org/10.1038/nature14539>

— Vaswani, Ashish و همکاران. «Attention Is All You Need». Advances in Neural Information Processing Systems (NeurIPS)، 12 ژوئن 2017.
<https://arxiv.org/abs/1706.03762>

— Brown, Tom B. و همکاران. «Language Models are Few-Shot Learners». NeurIPS، 2020.
proceedings.neurips.cc

— Kaplan, Jared و همکاران. «Scaling Laws for Neural Language Models». arXiv، 23 ژانویه 2020.
<https://arxiv.org/abs/2001.08361>

— Ouyang, Long و همکاران. «Training Language Models to Follow Instructions with Human Feedback». NeurIPS، 6 دسامبر 2022.
proceedings.neurips.cc

— Stanford Institute for Human-Centered Artificial Intelligence. «The 2025 AI Index Report».
hai.stanford.edu/ai-index/2025-ai-index-report